Fiche de conduite — les 10 étapes

Atelier TechWeek · Collège LaSalle · 2 h · 127.0.0.1 uniquement · aucun PDF dans le dépôt

Règle unique : une démo ratée ne se débogue pas en direct plus de 60 s. On dit « je garde ça pour la fin », on ouvre app_final.py, on continue.

#	Étape	Lancer (dossier mon_agent_react)	Ce que je montre	Ce que je dis	Question posée → réaction attendue
1	Le cerveau seul	`python etape1.py`	Une réponse en 3 s, en français, avec du code JSX.	« Il répond en trois secondes. Il n'a lu aucun de vos documents. »	Quelle est la date de l'examen du cours 420-TT4-AS ? → Refus poli, trois conseils, puis du code hors sujet. Aucune source.
2	La matière	`python etape2.py`	« useState » répond ; « useReducer » est refusé net.	« Le prompt est de la politesse. Le code, c'est la police. »	Explique useReducer. → Refus immédiat, 0 appel : la garde bloque avant le modèle.
3	Les mains	`python etape3.py`	La ligne [outil] lire_cours() apparaît avant la réponse.	« Un agent, ce n'est pas un modèle qui sait tout : c'est un modèle qui peut demander. »	Que dit le cours sur useState ? → Le modèle demande, Python lit, le modèle rédige.
4	Le visage	`python etape4.py`	La page s'ouvre sur 127.0.0.1:3000.	« Coupez le wifi : la page marche encore. Rien ne sort de la machine. »	Une question, wifi coupé. → Même réponse. Aucun réseau, aucune clé.
5	Le contrôle	`python etape5_web.py`	Quiz de 2 questions, score détaillé.	« Qui a corrigé ? Python. Combien d'appels au modèle ? Zéro. »	Répondre volontairement faux à la question 1. → « 1:A=NON->B » : la bonne réponse est affichée.
6	La bibliothèque	`python etape6_web.py`	Un snippet + la pastille banque_react.py:usereducer.	« Demandez le code : la réponse existe avant le modèle. »	donne le code usereducer → Code figé + pastille. 0 appel au modèle.
7	La mémoire documentaire	`python etape6_web_doc.py`	Une date juste + le nom du fichier du calendrier.	« Le calendrier n'est pas dans le prompt : il est lu à la question. »	Quand le cours 420-TT4-AS ? → Réponse instantanée, 0 appel, pastille du calendrier.
8	Le tri et la preuve	`python etape8.py --demo`	5 questions, 4 chemins, 2 appels au modèle (6 questions si le livre est indexé).	« Comptez avec moi : deux appels sur cinq. Le reste, c'est du Python. »	La batterie se joue seule, puis « Que dit le livre sur Redux et les reducers ? ». → Batterie : Tailwind → .docx ; date → 0 ; useReducer → .docx ; code → banque ; tarte → refus. → Livre : fullstack-react p.565, vérifiable dans le PDF.
9	La mesure	`python etape9_tokens.py`	Trois comptes de tokens, côte à côte.	« Vos notes ne rentrent pas. Ce n'est pas un bug : c'est la raison d'être du RAG. »	(pas de question : on mesure) → 8 192 tokens ≈ 30 000 caractères ; le corpus en fait 68 000.
10	L'ouverture	`python etape10_ressources.py`	La liste des livres présents + les 5 sites.	« Ouvrez le livre à la page 565 : la citation est vraie. C'est ça, une preuve. »	Que dit le livre sur Redux et les reducers ? → fullstack-react p.565, vérifiable dans le PDF.

Les cinq phrases à répéter

1. Le modèle propose, Python décide.
2. Pas de source, pas de réponse.
3. Le prompt est de la politesse ; le code, c'est la police.
4. Un agent sans preuve est un moteur à vraisemblance.
5. L'enseignant garde la note, le programme et la parole.

Ordre de coupe (décidé à froid)

Priorité	Étapes	Pourquoi
Bloquant (35 min)	1 · 3 · 8	Sans elles, il n'y a pas de démonstration, seulement des fonctionnalités.
Cœur (46 min)	2 · 4 · 6 · 7 · 10	Ce sont les preuves que le public peut vérifier lui-même.
Variable (17 min)	5 · 9	Remplaçables par une phrase si le temps manque : 9 → 3 min (tokens).

Si ça casse

Ollama ne répond pas — Lancer l'application Ollama, puis « ollama list ». Modèle absent : ollama pull llama3.2:latest.

Port 3000 occupé — Fermer l'ancien python (ou redémarrer le terminal), puis relancer.

Page blanche — Vérifier que le terminal affiche « Ouvrez http://127.0.0.1:3000 » ; utiliser 127.0.0.1, jamais localhost.

Une étape échoue — 60 s maximum. Sinon : « je garde ça pour la fin », puis app_final.py qui contient la même logique.

Question imprévue du public — La poser à l'agent en direct : c'est le meilleur test, et le refus est une réponse.

Après les dix étapes : les versions ultimate (3 min, sans lancer)

app_rag_pro.py (recherche sémantique, SentenceTransformer) → app_ia_final.py (+ OCR, voix) → app_ultimate_ia_*.py (+ mémoire, Socrate, RAG PRO, quiz) → app_ultimate_ia_production.py (+ login, logs_pedagogie.json, tableau de bord /admin, langue détectée).

Ne pas les lancer en direct : torch + sentence-transformers + easyocr ≈ 2 Go, et un premier lancement qui télécharge des modèles. Aujourd'hui easyocr n'est pas installé : le mode image est désactivé au démarrage, le reste tourne. Montrer le code et une capture de /admin.